
Digital Judaica Done Right

Leonid Dubinsky

Table of Contents

Introduction	3
What is this About?	3
History	3
Format	3
What do we want? (The Dream)	5
Аннотация	5
Введение	5
Что надо хранить	5
Текст	5
Аннотации	5
Иерархическая структура	6
Ссылки	6
Самокоррекции	7
Авторство	7
Что надо уметь	7
История изменений (XXX подход?)	7
Програмный интерфейс	7
Текстовый редактор	7
Обращение ссылок	7
Язык запросов	8
Текстовый поиск	8
Параллельные структуры	8
Авторство	9
Печать	9
Индивидуализация	9
Интерфейс	9
Кооперация	10
Основное: всё	10
Разное	10
Комерциализуемость/Привлекательность	11
Чувство вины	11
Градуированные платные услуги	11
Google	11
Разное	12
Связанные разработки	12
Открытые вопросы	12
Имя домена	12

Implementation	15
Approach	15
О стандартах	15
Тексты на разных языках, справа на лево, с кантиляцией... ..	15
TEI	15
Особые буквы	16
Аннотации	16
Перекрывающиеся структуры	16
Справа на лево XXX программный интерфейс?	16
Ссылки	17
Редакторы XMLa	17
Интерфейс	18
Technology	18
XML Databases	18
XQuery	19
XML and Java	19
XML Pipelines	19
WebDAV	21
XML and Wiki	21
Java Content Reporitory	21
Content management Systems	22
XForms	23
URLs	23
Metadata	24
Tanach Markup	25
Internal Wiki Markup	26
Notes	26
BUGS	26
Laying out classic Jewish texts	28
Sources of Free Texts	30
Jumping points	30
Texts	30
Wikisource	31
Texts in English	32

Introduction

What is this About?

We want to have a computer environment that supports and facilitates study and research of Jewish Orthodox texts. (Most of the technological pieces that we need to develop are not at all specific to Jewish Orthodox Texts. On the other hand, desire to facilitate study of such texts is our primary motivation.)

This "dream system" will record various information about the texts and support doing interesting things with them.

On the text level, we want to allow marking up names of people and places, index entries, logical structure of statements, user-defined tags and the like. On the structural level: allow capturing of multiple structures of the same text, for example - chapter/verse and pages of a printed edition. On the intra-text level: record links from one text to another with their types and other metadata, and support link reversal.

It should be possible to print any text with glosses formatted nicely.

The system should be accessible through a clean, even minimalist, but powerful web-based interface. Mass participation - proofreading of the texts, marking them up, clarifying the cross-references and such - should be very much supported.

History

Initial conversations in this area took place in 1992-1994, between Leonid Dubinsky and Baruch Gorkin. Most of the requirements were understood then, but not the need for universal web-availability and crowd-sourcing: access to the Internet was not what it is now.

We realized that a standard approach to text markup has to be used, and settled on SGML (XML did not yet exist).

In the summer of 2006, discussions restarted between Dubinsky and Gorkin. Crowd-sourcing and potential commercialization were discussed. In the Fall of 2006, Michael Koritz joined in.

Format

Some of the research notes, discussion items and conclusions related to this project were captured and published on the project's web site.

Standard XML formats for text publishing were tried: DocBook and TEI. Since the format that is likely to be used for the storage of the texts themselves is TEI, we wanted to use TEI as the format for publishing the project papers too. This turned out to be impractical, since there is no convenient way to edit TEI document over the web using wiki-like interface. It seems that some people tried creating packages with such functionality, but nothing is being developed now. There is the DocBook Wiki, but it's approach to section editing leaves much to be desired, and anyway, TEI and not DocBook is our preferred format. Also, the machinery for turning TEI into PDF had some issues [<http://listserv.brown.edu/archives/cgi-bin/wa?A2=ind0712&L=TEI-L&T=0&F=&S=&P=63>].

We then published in a form of wiki pages - some of them in Russian. A blog was deemed an appropriate format, since it captures a sense of development in time, allows comments and, hopefully, encourages smaller, but more frequent publication :)

As part of this project, we need to develop technology for web-based editing of big texts with rich markup and complex structure. When we have it, we'll use it for publishing our papers, so this is not the final format ;)

Onward!

What do we want? (The Dream)

Аннотация

Пора сформулировать, наконец, в письменном виде требования и подходы, и начать что-то делать.

Введение

Мы хотим хранить тексты в формате (Раздел 2), вмещающем всю информацию, нужную для поддержки интересных операций (Раздел 3) с текстами. Интерфейс (Раздел 5) должен завораживать своей минималистической правильностью, и главное - система должна быть построена вокруг кооперации (Раздел 6), в духе современных веяний. В частности, подключить народ к работе системы необходимо как можно раньше ("build it and they will come").

Что надо хранить

Текст

Надо хранить тексты на разных языках, некоторые из которых пишутся справа налево. В некоторых текстах на иврите будут огласовки, а то и кантиляция.

Бывают также "особые" буквы (уменьшенные, увеличенные, перевернутые), и надо их отметить.

Надо хранить фотографии рукописей или просканированные страницы книг. Возможно, и аудио- и видео- материалы.

Аннотации

Надо уметь отмечать textual features, то есть выделять и выявлять информацию, содержащуюся в тексте:

- Имена людей
- Названия мест
- Начальные слова комментариев
- Авторов высказываний

- Метод вывода в высказывания Талмуда
- Фразы, под которыми ссылки на этот фрагмент входят в индекс

Надо также уметь ассоциировать метаинформацию с фрагментами текста:

- На какой стадии вычитки находится фрагмент
- "Таги"

Иерархическая структура

Надо хранить иерархическую структуру текстов, используемую, в частности, для ссылок. Примеры: Текст Структура Танах книга, глава, стих Хумаш недельный раздел Хумаш парша (тип которой - открытая или закрытая - тоже надо хранить) Раши на Танах книга, глава, стих, комментарий Мишна трактат, глава, мишна Талмуд трактат, лист/сторона Талмуд трактат, глава, высказывание Рамбам [книга,] законы о, закон [, предложение] Шулхан Арух раздел, симан, сеиф[, сеиф котон]

Надо уметь хранить границы страниц, например, Талмуда, причем иногда - для нескольких изданий одного и того же текста. Возможность хранить границы строк тоже может пригодиться.

У одного текста может быть несколько иерархических структур (глава/стих и парша в Хумаше; страница и высказывание в Талмуде). Разные структуры могут быть "несовместимыми": парша может кончиться посреди стиха, а недельный раздел - посреди главы. Страницы в разных изданиях начинаются в разных местах, часто - посреди предложения.

Ссылки

Тексты ссылаются друг на друга. Ссылка соединяет отрезок или точку одного текста с отрезком или точкой другого.

Ссылки могут быть внешними по отношению к текстам, ими соединяемым. Например, список параллельных мест в Талмуде или источников Шулхан Аруха Альтер Ребе. Толдос...

Бывают разные типы ссылок:

- начало комментирует конец
- начало приводит доказательство/иллюстрирует концом
- начало транскрибирует конец

"Сила" ссылки.

Самокоррекции

Тип ссылки, обрабатываемый системой особым образом - коррекция.

Тексты могут корректировать другие тексты (Раши - Талмуд) или сами себя (Талмуд - цитаты из древних приведенные в нем). Текст может корректировать и ссылки, и структуру (разбиение на халохос в Рамбаме).

Авторство

Надо хранить много версий ("изданий") одного текста. Например, коррекции/выверки/впечатка фрагментов некоего текста одним пользователем - это "издание" (версия).

Что надо уметь

История изменений (XXX подход?)

Как source control system - слишком сложно. Нам бы что-нибудь попроще и постандартней...

It seems that branching and merging are necessary.

Программный интерфейс

Всё, что можно сделать через интерфейс пользователя, должна быть возможность сделать и через программный интерфейс тоже.

Доступ и изменения в различных форматах.

Add/change. Add/change metadata.

Look into AtomPub, WebDav and distributed source control - say, Mercurial.

Текстовый редактор

С текстами должно быть можно работать в текстовом редакторе.

Обращение ссылок

Надо уметь обращаться ссылки, т.е. перечислить, какие ссылки кончаются в указанном интервале.

Язык запросов

TODO

Текстовый поиск

Должен быть доступен текстовый поиск - с учетом структуры текстов и грамматики - и всякие другие поиски. Например:

- по ключевым словам
- все упоминания некоего города
- все высказывания определенного автора
- по титулу
- по разным языкам
- по последним добавлениям
- по группам пользователей
- близкие по "народному мнению"
- по "народному рейтингу"

Вот статья про поиск в анотированном тексте: [Information Retrieval from Annotated Texts]

Параллельные структуры

У некоторых текстов структуры параллельны хотя ни один не является комментарием другого. Например:

- перевод и оригинал
- разные издания одного текста
- Шулхан Арух Алтер Ребе и большой Шулхан Арух

Надо уметь сочетать тексты с параллельной структурой по этой структуре. Например, в виде подстрочного перевода.

Надо уметь ссылаться на набор текстов с параллельной структурой. Такие ссылки разрешаются на тот или иной конкретный текст (издание; язык; наличие огласовок) в зависимости от предпочтений пользователя.

Авторство

XXX "А от имени Б". То же - с пользовательскими текстами. Собственные комментарии - тоже тексты. XXX Как и обсуждения.

(Хумаш издания Кетер) по версии Васи; ((Рамбам глазами Роша) издания Ромм) по версии Пети.

Разница между версиями текста - тоже текст; текст с выделенными разночтениями.

Печать

Печать набора связанных текстов

Индивидуализация

- Личная программа учебы
- Дневные уроки - с записью "долгов"
- Создание собственной подборки текстов как на основе выборки из комментариев так и из результатов поиска
- Возможность компоновать выборки, сохранить их в памяти, распечатать

Интерфейс

Передвижение по текстам - горизонтальное и через таги (смысловое); поиск; выбор "фокуса": даф/сугъя; заметки: внести/просмотреть мои; недельная глава, последние и ближайшие шиурим, прошлые поиски юзера, последние поступления и т.д. От текста переход на соседние логические единицы текста, комментарии к нему (к выделенному юзером отрывку), поднятие к комментируемому им тексту, переводы и варианты. Список просмотренных сегодня текстов. "рабочий стол": выбранные тексты и большой лист для записей юзера - план урока или хидуш (конспект проведенной работы). Google Notebook. JotSpace [<http://www.jotspace.com/>].

Отец семейства хочет подготовить субботний разговор. Мы помним его любимых комментаторов, ему они предложены на "столе", при желании он находит дополнительные материалы на "полке", вытаскивает понравившиеся на лист, возможно добавляет список вопросов для детей. Текст и добавления идут в одном потоке

Подготовка драши к событию. Юзер выбирает из списка (бар мицва, бат мицва, брит, сиюм ...) события, затем из другого списка - шиури́м ему подходящие (недельная глава, Тания, Рамбам, ближайшие праздники) и на основе этого выбора он получает набор текстов.

Кроме побора текстов в формате "форума" может понадобиться например снимок листа Гемары.

Для урока в ешиве тихонит учитель может захотеть добавить виде-аудиоматериалы и разные картинки. (При обращении к внешним материалам надо продумать политику цензурирования, чтобы досов не спугнуть)

Презентации.

Кооперация

Основное: всё

Впечатывание текстов

Выверка текстов: Wikipedia, Wikisource, Distributed Proofreaders

Разметка текстов

Провязка текстов

Аннотирование

Новые стили подачи информации (XProc/XQuery/XSLT)

Новые стили печати

Разное

Дистанционность (web)

Интеграция с блогами

Wikipedia

Live Journal

Del.icio.us

Digital libraries

Юристы

Форумы для обсуждения: Wikipedia

Защита от саботажа: Wikipedia

Citizendium [64]

[http://many.corante.com/archives/2006/09/18/
larry_sanger_citizendium_and_the_problem_of_expertise.php](http://many.corante.com/archives/2006/09/18/larry_sanger_citizendium_and_the_problem_of_expertise.php) [http://
[Fmany.corante.com/archives/2006/09/18/
larry_sanger_citizendium_and_the_problem_of_expertise.php](http://many.corante.com/archives/2006/09/18/larry_sanger_citizendium_and_the_problem_of_expertise.php)]

[http://many.corante.com/archives/2006/09/20/
larry_sanger_on_me_on_citizendium.php](http://many.corante.com/archives/2006/09/20/larry_sanger_on_me_on_citizendium.php)

Уровни пользователей по репутации/возможностям (анонимный, зарегистрированный, редактор)

Редактор, сотвори редактора

Комерциализуемость/ Привлекательность

Чувство вины

Наша система должна стать частью еврейской культуры. Бохур, не взявший шефства над листом талмуда или главой ришона станет изгоем. С издательством, не подарившим нам 10 электронных текстов никто не будет иметь дела. Все спонсоры будут наши - у нас видно всему свету. Заповедь о написании Торы выполнять ходить будут к нам. Хаскомос давать будут через нас. Хидушим печатать будут у нас - как физики в arXive.

Увековечивание себя (или других людей) на страницах проекта.

Градуированные платные услуги

Предоставление дополнительных услуг за деньги. Например, хорошая печать. Или - доступ к "супервыверенным" текстам.

Google

Индивидуализация: GData.

Сканы.

Хорошо бы - их хостинг.

Ещё лучше - за их деньги.

Разное

Ксюхина идея: Юристы как рынок для серьезных денег?

Патент

Довесок к бумажной книге

Связанные разработки

TODO

Открытые вопросы

Имя домена

Как назвать? Кориц предложил два: OpenTorah и "Торат Моше".

Sources

[Fraenkel97] *The Responsa storage and retrieval system-whither?..* Aviezri Fraenkel. 1997. <http://www.wisdom.weizmann.ac.il/~fraenkel/Papers/trs.ps>. <http://www.wisdom.weizmann.ac.il/~fraenkel/Papers/pha.ps>.

[CAB] *The Cathedral and the Bazaar*. Eric S Raymond. <http://www.catb.org/~esr/writings/homesteading>.

[Ontology] *Ontology is overrated*. Clay Shirky. 2005. http://www.shirky.com/writings/ontology_overrated.html.

Distributed Proofreaders. <http://www.pgdp.net/c/default.php>.

TEI Lite Tutorial. http://www.tei-c.org/Lite/teiu5_split_en.html.

TEI P5. <http://www.tei-c.org/release/doc/tei-p5-doc/html/>.

TEI CE. <http://www.tei-c.org/Activities/CE/>.

TEI Overlap. <http://www.tei-c.org/Activities/SIG/Overlap/>.

TEI WD. <http://www.tei-c.org/release/doc/tei-p5-doc/html/WD.html>.

TEI NH. <http://www.tei-c.org/release/doc/tei-p5-doc/html/NH.html>.

TEI I18N. <http://www.tei-c.org/I18N/>.

TEI Roma. <http://tei.oucs.ox.ac.uk/Roma/>.

?. <http://www.w3.org/People/cmsmcq/2000/poddp2000.html>.

?. <http://www.mulberrytech.com/Extreme/Proceedings/html/2004/DeRose01/EML2004DeRose01.html>.

?. <http://www.idealliance.org/papers/extreme/Proceedings/html/2005/Bauman01/EML2005Bauman01.html>.

?. <http://www.tei-c.org.uk/wiki/index.php/SIG:Overlap>.

?. <http://www.tei-c.org/wiki/index.php/Talk:SIG:Overlap>.

?. <http://www.tei-c.org/Talks/OUCS/2005-02/talk-access.pdf>.

Subversion. <http://subversion.tigris.org/>.

eXist XML database. <http://exist.sourceforge.net/>.

JXHTML EDIT. http://www.tecnick.com/public/code/cp_dpage.php?aiocp_dp=jxhtmledit.

Syntext Serna. <http://www.syntext.com/products/serna/index.htm>.

Stylus Studio. <http://www.stylusstudio.com/>.

ALTOVA xmlspy. <http://www.altova.com/>.

oXygen. <http://www.oxygenxml.com/>.

Exchanger XML. <http://www.exchangerxml.com/editor/>.

editix. <http://www.editix.com/>.

topologi. <http://www.topologi.com/>.

Ajax. <http://en.wikipedia.org/wiki/AJAX>.

Applets. http://jroller.com/page/tackline?entry=using_applets_in_place_of.

Applets. <http://weblogs.java.net/blog/chet/applet-jax/Yapplet.html>.

Thank God - Java EE Is Not Like Ajax. http://www.coachwei.com/blog/_archives/2006/9/27/2367882.html.

Unicode. <http://www.unicode.org/>.

Unicode. <http://www.w3.org/International/articles/inline-bidi-markup/>.

XML. <http://www.xml.com/axml/testaxml.htm>.

XLink. <http://www.xml.com/pub/a/2002/03/13/xlink.html>.

Wikipedia: Tim Bray. http://en.wikipedia.org/wiki/Tim_Bray.

<http://www.w3.org/People/cmsmcq/>.

Theological Markup Language. <http://www.ccel.org/ThML/ThML1.04.htm>.

Tanakh ML. <http://tanakhml2.alacartejava.net/cocoon/tanakhml/index.htm>.

Open Scripture Information Standard. http://en.wikipedia.org/wiki/Open_Scripture_Information_Standard.

Project Gutenberg. <http://www.gutenberg.org>.

Citizendium. <http://www.citizendium.org/cfa.html>.

No new XML languages. <http://www.tbray.org/ongoing/When/200x/2006/01/08/No-New-XML-Languages>.

<http://www.unicode.org/charts/PDF/U0100.pdf>.

<http://www.unicode.org/charts/PDF/U0590.pdf>.

Topic Maps. http://en.wikipedia.org/wiki/Topic_map.

?. <http://www.ontopia.net/topicmaps/materials/tmrdf.html>.

Information retrieval from annotated texts.. A.S. Fraenkel and S.T. Klein. J.. Amer. Soc. for Information Sciences. 50. 1999. 845-854.. <http://www.wisdom.weizmann.ac.il/~fraenkel/Papers/annot.ps>.

http://scripts.sil.org/cms/scripts/page.php?site_id=nrsi&item_id=XSEM.

<http://books.chabadlibrary.org/default.aspx>.

пример того как из внешним образом аннотированного текста в XMLe можно получить HTML.

Implementation

Approach

О стандартах

Если есть стандарт, то ясно, что лучше использовать его, чем своё, доморощенное. Выгода от этого понятна: стандарт поддерживается всеми (или многими), а доморощенное - никем; программы, понимающие стандарт, используются широко и отлажены лучше, чем будут отлажены доморощенные (которые ещё и писать придется); люди про стандарт слышали и знают, как с ним работать и т.д. Но главное - сам стандарт, будучи результатом чудовищного количества труда специалистов, как правило "отлажен" лучше, чем любая частная разработка.

Бывает, что стандарт "не прижился". Тогда многие из выгод от его использования пропадают. Но если в какой-то области есть "прижившийся" стандарт, понятно, что игнорировать его очень глупо. Несмотря на то, что из-за "комитетности" разработки многих стандартов в них случаются компромиссы, а из-за длительности процесса стандартизации "последнее слово" в них может быть и не отражено.

Тексты на разных языках, справа на лево, с кантиляцией...

Ясно, что тексты должны храниться в Unicode [53]. Придумывать свою кодировку неразумно.

Ясно, что тексты должны храниться в XMLe [55] [1], несмотря на то, что он не рассчитан на представление нескольких структур одного текста (см. ниже). Тем не менее, придумывать свой, "улучшенный" XML неразумно.

TEI

Один из авторов XMLa, Тим Брай [58], велит не изобретать своих форматов XMLa, а воспользоваться одним из пяти "основных" [65]. В области представления в XMLe "гуманитарных" (извините за выражение) текстов есть стандарт (не включённый Браем в число "основных"): рекомендации TEI (Инициатива Кодировки Текстов) [6]. Долгие годы его разработку возглавлял другой из авторов XMLa - Майкл Сперберг-Маккуин [59]. Ясно, что надо им воспользоваться.

(С другой стороны, хорошо бы понять, почему многие им не пользуются или пользуются лишь частично: Theological Markup Language [60], TanakhML [61], Open Scripture [62], Project Gutenberg [63].)

Особые буквы

В наших текстах могут быть особые буквы (Раздел 2.1). В TEI вопросами кодировки особых букв занималась специальная рабочая группа [7]. Им посвящена глава рекомендаций [9].

Аннотации

Аннотации - место, имя ... - в TEI есть.

Перекрывающиеся структуры

Наши тексты могут иметь несколько пересекающихся иерархических структур (Раздел 2.3). Причем это касается не только Танаха или текстов с многими изданиями и границами страниц. Один из фундаментальных вопросов, на которые должно уметь отвечать наше текстовохранилище, это "какие тексты ссылаются на данный". Ответ на такой вопрос видится мне как интересующий нас текст в который добавлены "обратные" ссылки на тексты, на него ссылающиеся. Но "концы" ссылок - которые теперь стали "началами" обратных ссылок - это фрагменты нашего текста, и они запросто могут перекрываться.

Какое-нибудь решение этой проблемы можно придумать не сходя с места. Возможно, даже несколько. Но продумать их во всех деталях, попробовать на практике, сравнить и т.д. займёт годы. Люди, занимающиеся TEI [6], их уже потратили, уделили этому вопросу главу Рекомендаций [10], организовали рабочую группу [8], и продолжают тратить: [13] [14] [15] [16] [17] .

Справа на лево XXX программный интерфейс?

Наши тексты пишутся в основном на иврите, арамейском и идише - справа на лево (Раздел 2.1). Таги TEI (и всех известных мне XML-форматов) пишутся по-английски и, естественно, слева на право. Хорошо известно как представить двунаправленный документ в XHTMLe так, чтобы все шло в нужную сторону, и чтобы при этом не использовались невидимые символы Unicode, меняющие направление текста [54]. Нам, однако, надо облегчить редактирование наших текстов в текстовом редакторе (возможно, понимающем XML). Если таги пишутся не в том направлении, что текст, такое редактирование практически, на мой

взгляд, нереально. А без использования невидимых символов изменения направления - невозможно.

Упражнение: используя ваш любимый редактор, введите таги посука `<verse>` и `</verse>`, а потом напечатайте между ними посук на иврите. Не столкнулись ли вы с неожиданностями? Например, не меняется ли направление текста когда вы вводите пробел рядом с угловой скобкой обрамляющей таг? Не вводятся ли при этом слова в обратном порядке? К какому слову посука ближе открывающий таг - к первому или к последнему?

Я не уверен, что если сами таги будут на иврите, то все проблемы ввода текста исчезнут - но я уверен, что хуже не станет. Есть ещё одна причина хотеть, чтобы таги были на иврите: многие наши потребители и участники английского не знают, и даже в пределах набора тагов TEI узнавать его не захотят - и я их понимаю. Было бы неправильно лишить возможности серьёзной обтаговки именно тех, кто на неё больше всех способен. А серьёзная обтаговка возможна только в текстовом редакторе: не только потому, что часто это удобнее, чем всевозможные web-интерфейсы, но и потому, что web-интерфейса, поддерживающего все таги TEI нам не написать. А в серьёзной работе очень многие из них нужны.

Казалось бы, если таги в наших текстах будут на иврите, то это уже не TEI? Не тут то было! TEIвцы начали работать над интернализацией: хотят сделать свою штукину доступной неанглоязычным [11]. Вообще, у них в последней версии - P5 - пользователь может адаптировать схему, которую генерирует программа ROMA [12], на свою ситуацию.

В любом случае, мы можем хранить тексты в TEI, но позволять доставать их в другом формате, менять и засовывать обратно. Многие так и делают. Так мы можем, например, ввести структурные таги, более уместные в конкретных текстах, чем довольно общие структурные таги TEI.

Ссылки

Наибольшее беспокойство у меня вызывают ссылки. Они в TEI могут оказаться недостаточно мощными и гибкими. Нам, похоже, просто XLink (XPointer?) [57] не подойдёт: надо посмотреть на Topic Maps [70] и RDF [71].

Редакторы XMLa

Наш web-интерфейс должен поддерживать довольно серьёзное редактирование документов на XML. Редакторы такого рода существуют. Например: JXHTMLaEDIT [41] (для HTMLa), Syntext Serna [42]

(коммерческий). Однако, как ни крути, а надо мочь редактировать наши тексты (XML, TEI) в нормальном редакторе. Раздел 3.3 тоже. Я слышал много хорошего про Stylus Studio [43] и ALTOVA xmlspy [44] - оба только для Windows. Есть несколько написанных на Java - и потому работающих везде: oXygen [45], Exchanger XML [46], editix [47], Topologi [48]. Мне из них настолько больше понравился Oxygen, что я его купил.

Интерфейс

{Browser} {Tabs}

Сейчас моден AJAX [49]. Я предпочел бы его избежать при возможности, а для динамизма воспользоваться какими-нибудь невидимыми Java-скими апплетами [50] [51], что ли... Вот интереснейшая заметка [52] о проблемах с AJAXом. Написана она человеком, который подобными штуками занимается уже лет 10.

Technology

XML Databases

It is possible to store the texts as XML files in the file system and use XSLT (as implemented by Saxon) to select requested pieces and transform them into presentation form. Indeed, I'll have a copy of all the texts in simple XML files anyway, since I need to check the texts into a revision-control system.

It seems likely, though, that I'll need to store the texts (also) in an XML database. Here are some requirements that make me think so:

- Access parts of documents in response to a query
- Fetch fragments of the documents referenced from a given one
- Find documents referencing a given one (link reversal)
- Full text search

Only first of these requirements can realistically be satisfied without some indexes. On the other hand, only first two are trivially satisfied by an XML database (like Exist). Integration between Lucene text indexing package and Exist needs to be looked into. As for link reversal, we'll probably have to write the indexer and accessor ourselves...

It is clear that a query language to be used is XQuery [<http://isbn.nu/0321180607>]. It is a nice, functional, non-statically-typed language, that have recently acquired update and text search capabilities. (XXX)

TEIвцы тоже согласны, что надо пользоваться XMLьными базами данных и XQuery [18].

Информацию о различных XMLьных базах данных приводит ? Bourret [<http://www.rpbourret.com/>]. Некоторые бесплатные базы данных для XMLa:

- eXist [<http://exist-db.org/>]
- Berkeley DB XML [<http://www.sleepycat.com/products/bdbxml.html>]
- Sedna [<http://modis.ispras.ru/sedna/index.htm>]
- Timber [<http://www.eecs.umich.edu/db/timber>]
- MarkLogic [<http://xqzone.marklogic.com/>]
- Lucene [<http://lucene.apache.org/>]

XQuery

Some use XQuery as the (almost) only implementation language for the application (e.g., AtomicWiki [<http://judaica.podval.org/moin/AtomicWiki>]). XQuery *is* a functional language. But XQuery does not have static typesystem or exception processing. I will use Java (or Scala) as my main implementation language, and XQJ to access XQuery/XSLT processors.

XML and Java

There are APIs for

- parsing: javax.xml.parsers
- XSLT: javax.xml.transform
- XPath: javax.xml.xpath
- XQuery (XQJ): java.xml.query

javax.xml.xpath only supports XPath version 1

It seems that I can do pipelines using XQJ.

XML Pipelines

- Cocoon [<http://cocoon.apache.org/>]

- Pipelines [<http://moinmo.in/FeatureRequests/PipelineArchitecture>]
- XProc
- Calabash [<http://fgeorges.blogspot.com/2008/10/poor-mans-calabash-integration-into.html>]

Пока что я обнаружил только две системы текстовохранилищ ориентированных на TEI: Versioning Machine Versioning Machine [<http://mith2.umd.edu/products/ver-mach/>] и <teiPublisher> [<http://teipublisher.sourceforge.net/docs/index.php>]. Обе делали одни и те же люди - Susan Schreibman [<http://www.greenstone.org/cgi-bin/library>] и Amit Kumar, и обе заглохли. Вторая даже использовала eXist.

Нам надо хранить не только сам документ, но и историю его изменений: кто, когда и что. Это даёт возможность вернуться к любому состоянию, посмотреть историю, заблокировать слишком быстрое изменение текста и т.д. Для этого надо прирастить к базе данных готовую version control system (XXX не очевидно), а именно - SubVersion [<http://judaica.podval.org/moin/SubVersion>]? Hg?.

К текстовохранилищу должен быть доступ через сетевые протоколы, а не только через web-интерфейс. Программный доступ к текстовохранилищу должен быть возможен разный: через

- WebDAV [<http://www.webdav.org/>]
- REST
- SOAP [<http://en.wikipedia.org/wiki/SOAP>]
- XML-RPC [<http://en.wikipedia.org/wiki/XML-RPC>]
- XML:DB [<http://xmldb-org.sourceforge.net/>]
- RSS [http://en.wikipedia.org/wiki/RSS_%28file_format%29]
- Atom [http://en.wikipedia.org/wiki/Atom_%28standard%29]
- SubVersion/Hg
 - Индексация ссылок и меток
 - Импорт (Хумаш) и прямое использование (сканы) внешних ресурсов
 - Annotea [<http://www.w3.org/2001/Annotea/>]
 - Collate/Anastasia

WebDAV

XML and Wiki

- AtomicWiki [<http://code.google.com/p/atomicwiki>]
- WikiModel [<http://code.google.com/p/wikimodel>]
- WikiModel [<http://wikimodel.sourceforge.net/>]
- XmlWiki [<http://moinmo.in/XmlWiki>]
- WikiXmlDtd [<http://www.usemod.com/cgi-bin/mb.pl?WikiXmlDtd>]
- DocBookWiki [<http://doc-book.sourceforge.net/homepage>]
- Single Source Publishing [http://www.cecc.com.au/cb_pages/publishing.php]

Java Content Repository

Добавив к текстовому хранилищу интерфейс (и кое-что ещё :)), получаем Content Repository System.

Есть стандарт в области доступа к хранилищу из Java: JSR 170. Это может быть интересно для нас - а может и не быть. Кстати, в разработке этого стандарта активное участие принимал Рой Филдинг, автор известной диссертации [http://www.ics.uci.edu/~fielding/pubs/dissertation/rest_arch_style.htm#sec_5_2_3] про REST [<http://rest.blueoxen.net/cgi-bin/wiki.pl?FrontPage>] и один из архитекторов Интернета - а в настоящий момент, архитектор в компании Day [<http://www.day.com/site/en/index.html>], продающей такое хранилище :). Есть бесплатная реализация: Apache Jackrabbit.

How do I return XML documents as XQJ-valued properties? My stuff is going to be stored in XML database (or a bunch of files processed by Saxon). I can not present them as files (because they may not be) that need to be parsed (especially when they are already parsed and indexed). So my only (standard) choice to glue the low-level store to Java is XQJ.

How do I project one hierarchy on top of another in JCR? Let's say I store files with texts in the repository. I need to expose the result (both through WebDAV and locally) as a hierarchy where I can drill into the documents' hierarchical structure (chapter, paragraph etc). I will do it through XQuery (likely XPath, but running within XQuery engine). Also, there may be multiple such structures, and before drilling in I will need to turn main structure into an alternative one using XSLT. I'd like the *external* view to have the same JCR API.

- At Wikipedia [http://en.wikipedia.org/wiki/Content_repository_API_for_Java]
- A Practitioner's Perspective [<http://www.theserverside.com/tt/articles/article.tss?l=JCRPract>]
- JSR 170 [<http://jcp.org/en/jsr/detail?id=170>]
- What is Java Content Repository? [<http://www.onjava.com/pub/a/onjava/2006/10/04/what-is-java-content-repository.html>]
- JSR 283 [<http://jcp.org/en/jsr/detail?id=283>]
- Version 2 [<http://www.infoq.com/news/2007/07/java-content-repository-2>]

Примеры:

- Apache Jackrabbit [<http://jackrabbit.apache.org/index.html>]
- Apache Lenya [<http://lenya.apache.org/>]
- Apache Graffito [<http://incubator.apache.org/graffito/>]
- OpenCMS [<http://www.opencms.org/opencms/en/>]
- DSpace [<http://www.dspace.org/>]
- Fedora [<http://www.fedora.info/>]
- Greenstone [<http://www.greenstone.org/cgi-bin/library>]

Content management Systems

- A list [<http://java-source.net/open-source/content-managment-systems>]
- <http://www.day.com/site/en/index.html>
- Daisy [<http://www.outerthought.com/en/products/daisy>]
- Daisy [<http://cocoonddev.org/daisy>]
- Apache Lenya [<http://lenya.apache.org/>]
- Apache Forrest [<http://forrest.apache.org/>]
- Apache Graffito [<http://incubator.apache.org/graffito>]
- OpenCMS [<http://www.opencms.org/opencms/en>]
- DSpace [<http://www.dspace.org/>]

- Alfresco [<http://www.alfresco.com/>]
- Magnolia [<http://www.magnolia-cms.com/>]

XForms

- Chiba [<http://chiba.sourceforge.net/>]
- Orbeon Forms [<http://www.orbeon.com/>]
- Firefox Extension
- FormFaces [<http://judaica.podval.org/moin/FormFaces>]

Tagsoup

URLs

XPointer in the URI, not in the fragment! No delimiters, just URI parts - which can be implicit (not "chapter=3", but "chapters/3", or just "3")! Editions in the URI ("Chumash/boston+toronto/Genesis")! Metadata ("about"), raw XML etc. - in the URI, not as query parameter ("Genesis/about", "chapters/1/raw")! More URI promotion: natural references ("Genesis/2:1", "Genesis 2:1")! Intervals ("Genesis/2:1-3")! Concatenation ("Genesis/2:1-3;5") probably shouldn't be done through URIs!

Books URIs:

`/books/Tanach/editions/.../[parts/...]/books/.../[weeks/...]/chapters/.../verses/...`

editions: a | a+b (side-by-side) | a-b (differences)

parts: Torah | Neviim | Ksuvim

books: Genesis | Ionah | ... (appropriate for part if present)

weeks: Genesis | Noah | ...

chapters: n | m-n

verses: n | m-n (can be present only if one chapter is selected)

Alternative names may be used.

URL may be truncated.

Parts of the URL may be implied - and need to be derived.

Metadata

Metadata is used to:

- guide navigation
- provide listings and names
- create classifications (links)
- stitch together data directories
- store application-specific metadata

Some of the data in it has to be duplicated in the text document (for self-containment, *and* for non-position-based navigation).

We need to be able to handle things like "Chumash/books/Genesis/weeks" and "Chumash/weeks" with one metadata document...

Locators for the navigational steps can be: - subdirectory/file - element XPATH
- milestone XPATH

1) I need to be able to provide a list of selectors (book name/ chapter #/ verse# etc.) on any level.

2) A selector can have multiple names, which I do not want to duplicate (and maintain) in each edition of the text. So, selector names have to be part of the metadata.

3) A text can have multiple structures. They are important for the metadata also. Restructuring of the text is done by XSLT. It seems logical to use the same for the restructuring of the metadata.

It follows that the metadata needs to be processable as XML (and have format similar to the texts). Do I also need it to be processable (in part) as Java objects (using JAXB) - is not clear.

We are going to use milestones [?] to represent multiple structures.

```
<book n="Genesis">
  <chapter n="1">
    <week n="Genesis" milestone="begin"/>
    <paragraph type="open" milestone="begin"/>
```



```
<verse n="1">
....
</verse>
</chapter>
...
<chapter n="6">
  <verse n="1">
    ...
    <week n="Noach" milestone="begin"/>
    <verse n="..">
      ...
  </chapter>
</book>
```

Tanach Markup

What are the TEI-appropriate tags for Tanach? How do we represent the paragraph in the middle of the verse?

Super-Wiki

Wiki with multiple formats => function reversal (TEI->HTML; edit; back)...

Wiki page rename and links correction - if the wiki itself is in an XML database (like AtomicWiki [<http://judaica.podval.org/moin/AtomicWiki>]) *with* our link-reversal index, wouldn't it be easier? History will be kept by the revision-control system...

Navigation:

- expand/contract viewport
- move viewport
- switch to a different structure preserving focus (from "lesson" to "chapter" in Tanya, for instance)

- switch to a different edition / look around at editions

Internal Wiki Markup

<section level="" milestone=""/> 1 2 3 4 start

<list type=""> bullets numbers

- <item>

<table>

- <row>

- <item>

<paragraph>

<blockquote>

<line>

<style type=""> emphasize bold italics underline strikethrough

<anchor id="">

<wikiLink relative="" reference="">

<interWikiLink name="" reference="">

<urlLink reference="">

<include> image?

Notes

crowd-sourcing TEI files [http://comments.gmane.org/
gmane.text.tei.general/7031]

Web-based IDE with WebDAV's versioning

BUGS

Upstream:

- http://sourceforge.net/tracker/index.php?func=detail&aid=2056090&group_id=17691&atid=117691 exist resolve-url

- <http://xmlroff.org/ticket/131> xmlroff tables (fixed)

Sebastian:

- File a bug against FO stylesheets (title, table of contents).
- File a bug about reference shape consistency.
- File a bug about use of @name for reference.

Saxon, Tomcat and relative URIs for the stylesheets. XQuery Server Pages (and eXist).

space before a word that has read/write annotations (Psalm 60)

Styles of biblio references.

Google SSO. GData. RSS/Atom - second edition? Hacking...?

Start working on XSLT: Genesis -> FO

leningrad-import:

- remove stylesheet link
- add TEI P5 All declaration; namespace(s)
- makaf

XProc

Discussions as text.

Convince CiteULike to make their XHTML really XHTML, or at least - well-formed XML. Better - parse RIS.

Laying out classic Jewish texts

It is natural for a user, after researching with our system, to desire to print selected texts and fragments for personal - or group - study away from a computer. Such printouts are one-use artifacts. It is clear that ability to produce such printouts must be present in the system from the beginning. The question is: how good the typographically does it need to be?

We need to format a tree of texts: main one, commentaries of it, commentaries on commentaries etc. It is known about each piece of commentaries what is it commenting on. All the font metrics are also known: glyph sizes, what is haging how low and what is sticking up and how high. Result needs to be readable and (is it a separate requirement?) beayfull.

To format "like in a book", we need to optimize the following contradicting constraints (the list is probably incomplete):

- the page must be fully covered with print
- comment must start on the same page where what it comments on is
- comment must end on the page it started

Koritz says that we do not need to print books, but "leaflets" instead: text with comments that fit on one page. In the "forum format", whatever that means.

Gorkin says that printing "like in the book" of the multi-layered text is extremely challenging typographically, and thus very interesting, but design of the overall interface of the system is even more interesting - and difficult. And more importants. Also, what exactly are the requirements for the printing facility, and what is their order of importance, will become clear only in the process of using the system. So, initially printing needs to be acceptable, but primitive - we do not have resources to do fancy stuff from the beginning.

Dubinsky says that the format that will "grow" from the use of the system, will turn out to be a familiar to us all format "like in the book", or so close to it, that a solution for one will fit the other; that good leaflet is not easier to print than a book; and that ability to print familiar "book-like" format is neccessary for the psychological comfort of the users. But he also agrees that features and interface of the system are more important.

Thus, everybody agrees that initial printing facility will be "primitive". Gorkin does not want to expend any effort to even find out how primitive. Dubinsky would like to see something acceptable. Nothing of the sort has been found so far. XSL-FO [7] is insufficiently expressive for our problem - even version 1.1, it seems.

Beyond Pretty-Printing: Galley [http://lambda-the-ultimate.org/
node/2419] Concepts in Document Formatting Combinators

Nonpareil [http://www.it.usyd.edu.au/~jeff/nonpareil/]

iText [http://www.lowagie.com/iText/]

XSL-FO 2.0 Requirements [http://www.w3.org/TR/2008/WD-xslfo20-
req-20080326/]

Sources of Free Texts

Jumping points

- Wikipedia Torah database [http://en.wikipedia.org/wiki/Torah_database] - done
- Wikisource Judaica Bookshelf [http://he.wikisource.org/wiki/%D7%90%D7%A8%D7%95%D7%9F_%D7%94%D7%A1%D7%A4%D7%A8%D7%99%D7%9D_%D7%94%D7%99%D7%94%D7%95%D7%93%D7%99]
- psychomystic [<http://psychomystic.blogspot.com/search/label/Torah%20Online%20Links%20Database>] links - done - closed access
- Chabad Library [<http://chabadlibrary.org/books/>]
- Sichos Kodesh [<http://www.sichoskodesh.com/>] - empty
- Otzar 770 [<http://www.otzar770.com/>]
- hebrewbooks.org [<http://www.hebrewbooks.org/>]
- chabadlibrarybooks.com [<http://www.chabadlibrarybooks.com/>]
- Seforim Online [<http://www.seforimonline.org/>]
- Grimoar [<http://www.hebrew.grimoar.cz/>] - Kabbalah
- jewishcontent.org [<http://www.jewishcontent.org/>] - for PDAs
- Torah Texts [<http://www.torahtexts.org/>]
- chassidus.ru [<http://chassidus.ru/rambam/index.php>] - broken
- Halacha Brura [<http://www.halachabrura.org/alephlink.htm>]
- Digitized Book Repository (JNUL) [http://www.jnul.huji.ac.il/dl/books/html/bk_sub.htm] - broken
- Otzar HaHochma [<http://www.otzar.org/otzaren/indexeng.asp>]

Texts

- Tanach (Leningrad Codex) [<http://www.tanach.us/Tanach.xml>]
- Mishna [<http://chaver.com/Mishnah/TheMishnah.htm>]

- Targumim [<http://cal1.cn.huc.edu/index.htm>]
- Midrash Raba [<http://www.tsel.org/torah/midrashraba/index.html>]
- Midrash Tanhuma [<http://www.tsel.org/torah/tanhuma/index.html>]
- Yalkut Shimoni [<http://www.tsel.org/torah/yalkutsh/index.html>]
- Ovot DeRabbi Noson [<http://www.tsel.org/torah/avotrnatan/index.html>]
- Sefer HaHareidim [<http://www.daat.ac.il/daat/mahshevt/kitsur/tohen.htm>]

Wikisource

- ... and Mechon Mamre [http://he.wikisource.org/wiki/%D7%A9%D7%99%D7%97%D7%AA_%D7%95%D7%99%D7%A7%D7%99%D7%98%D7%A7%D7%A1%D7%98:%D7%95%D7%99%D7%A7%D7%99%D7%98%D7%A7%D7%A1%D7%98_%D7%95%D7%9E%D7%9B%D7%95%D7%9F_%D7%9E%D7%9E%D7%A8%D7%90]
- Tanach [<http://he.wikisource.org/wiki/%D7%9E%D7%A7%D7%A8%D7%90>]
- Mikraot Gdolot [http://he.wikisource.org/wiki/%D7%9E%D7%A7%D7%A8%D7%90%D7%95%D7%AA_%D7%92%D7%93%D7%95%D7%9C%D7%95%D7%AA]
- Targumim [<http://he.wikisource.org/wiki/%D7%AA%D7%A8%D7%92%D7%95%D7%9D>]
- Mishna [<http://he.wikisource.org/wiki/%D7%9E%D7%A9%D7%A0%D7%94>]
- Tosefta [<http://he.wikisource.org/wiki/%D7%AA%D7%95%D7%A1%D7%A4%D7%AA%D7%90>]
- Masechtos Ktanos [http://he.wikisource.org/wiki/%D7%9E%D7%A1%D7%9B%D7%AA%D7%95%D7%AA_%D7%A7%D7%98%D7%A0%D7%95%D7%AA]
- Mechilta [<http://he.wikisource.org/wiki/%D7%9E%D7%9B%D7%99%D7%9C%D7%AA%D7%90>]
- Sifro [<http://he.wikisource.org/wiki/%D7%A1%D7%A4%D7%A8%D7%90>]
- Sifri [<http://he.wikisource.org/wiki/%D7%A1%D7%A4%D7%A8%D7%99>]
- Midrash Rabba [http://he.wikisource.org/wiki/%D7%9E%D7%93%D7%A8%D7%A9_%D7%A8%D7%91%D7%94]

- Talmud Bavli [http://he.wikisource.org/wiki/%D7%AA%D7%9C%D7%9E%D7%95%D7%93_%D7%91%D7%91%D7%9C%D7%99]
- Talmud Yerushalmi [http://he.wikisource.org/wiki/%D7%AA%D7%9C%D7%9E%D7%95%D7%93_%D7%99%D7%A8%D7%95%D7%A9%D7%9C%D7%9E%D7%99]
- Rif [<http://he.wikisource.org/wiki/%D7%A8%D7%99%22%D7%A3>]
- Rambam [http://he.wikisource.org/wiki/%D7%9E%D7%A9%D7%A0%D7%94_%D7%AA%D7%95%D7%A8%D7%94]
- Tur [http://he.wikisource.org/wiki/%D7%90%D7%A8%D7%91%D7%A2%D7%94_%D7%98%D7%95%D7%A8%D7%99%D7%9D]
- Shulchan Oruch [http://he.wikisource.org/wiki/%D7%A9%D7%95%D7%9C%D7%97%D7%9F_%D7%A2%D7%A8%D7%95%D7%9A]
- Kitzur [http://he.wikisource.org/wiki/%D7%A7%D7%99%D7%A6%D7%95%D7%A8_%D7%A9%D7%95%D7%9C%D7%97%D7%9F_%D7%A2%D7%A8%D7%95%D7%9A]
- Oruch HaShulchan [http://he.wikisource.org/wiki/%D7%A2%D7%A8%D7%95%D7%9A_%D7%94%D7%A9%D7%95%D7%9C%D7%97%D7%9F] and? [<http://he.wikisource.org/wiki/AHS:OCH>]
- Shulchan Oruch HaRav [http://he.wikisource.org/wiki/%D7%A9%D7%95%D7%9C%D7%97%D7%9F_%D7%A2%D7%A8%D7%95%D7%9A_%D7%94%D7%A8%D7%91]
- Siddur Tora Or [http://he.wikisource.org/wiki/%D7%A1%D7%99%D7%93%D7%95%D7%A8_%D7%AA%D7%95%D7%A8%D7%94_%D7%90%D7%95%D7%A8]

Texts in English

- Babylonian Talmud: Soncino [<http://www.come-and-hear.com/talmud/index.html>] Rodkinson [<http://www.sacred-texts.com/jud/talmud.htm>]
- The Guide for the Perplexed [<http://www.sacred-texts.com/jud/gfp/index.htm>]
- Shulchan Aruch [<http://www.torah.org/advanced/shulchan-aruch/>]